UNIVERSITATEA ”ALEXANDRU-IOAN CUZA” DIN IAȘI

FACULTATEA DE INFORMATICĂ



LUCRARE DE LICENȚĂ

Simularea interacțiunilor pradă-prădător prin NEAT

propusă de

Daniel Apostu

Sesiunea: iunie/iulie, 2023

Coordonator științific

Lect. Dr. Croitoru Eugen

UNIVERSITATEA ”ALEXANDRU-IOAN CUZA” DIN IAȘI

FACULTATEA DE INFORMATICĂ

Simularea interacțiunilor pradă-prădător prin NEAT

Daniel Apostu

Sesiunea: iunie/iulie, 2023

Coordonator științific

Lect. Dr. Croitoru Eugen

Avizat,
Îndrumător lucrare de licență,
Lect. Dr. Croitoru Eugen.
Data: ..... Semnătura: .....

Declarație privind originalitatea conținutului lucrării de licență

Subsemnatul **Apostu Daniel** domiciliat în **Republica Moldova, r. Nisporeni, s. Grozești, str. Prutețului**, născut la data de **28 decembrie 2001**, identificat prin CNP **5011228803916**, absolvent al Facultății de informatică, **Facultatea de informatică** specializarea **informatică**, promoția 2023, declar pe propria răspundere cunoscând consecințele falsului în declarații în sensul art. 326 din Noul Cod Penal și dispozițiile Legii Educației Naționale nr. 1/2011 art. 143 al. 4 și 5 referitoare la plagiat, că lucrarea de licență cu titlul **Simularea interacțiunilor pradă-prădător prin NEAT** elaborată sub îndrumarea domnului **Lect. Dr. Croitoru Eugen**, pe care urmează să o susțin în fața comisiei este originală, îmi aparține și îmi asum conținutul său în întregime.

De asemenea, declar că sunt de acord ca lucrarea mea de licență să fie verificată prin orice modalitate legală pentru confirmarea originalității, consimțind inclusiv la introducerea conținutului ei într-o bază de date în acest scop.

Am luat la cunoștință despre faptul că este interzisă comercializarea de lucrări științifice în vederea facilitării falsificării de către cumpărător a calității de autor al unei lucrări de licență, de diplomă sau de disertație și în acest sens, declar pe proprie răspundere că lucrarea de față nu a fost copiată ci reprezintă rodul cercetării pe care am întreprins-o.

Data: ..... Semnătura: .....

Declarație de consimțământ

Prin prezenta declar că sunt de acord ca lucrarea de licență cu titlul **Simularea interacțiunilor pradă-prădător prin NEAT**, codul sursă al programelor și celelalte conținuturi (grafice, multimedia, date de test, etc.) care însoțesc această lucrare să fie utilizate în cadrul Facultății de informatică.

De asemenea, sunt de acord ca Facultatea de informatică de la Universitatea ”Alexandru-Ioan Cuza” din Iași, să utilizeze, modifice, reproducă și să distribuie în scopuri necomerciale programele-calculator, format executabil și sursă, realizate de mine în cadrul prezentei lucrări de licență.

Absolvent **Daniel Apostu**

Data: ..... Semnătura: .....

Cuprins

Motivație **2**

Introducere **4**

1 NEAT **7**

1.1 Retele Neuronale Artificiale 8

1.2 Problemele in TWEANNs si inovatiile in NEAT 9

1.2.1 Codificare 9

1.2.2 Initializarea populatiei 10

1.2.3 Problema conventiilor concurente si numerele de inovatie 11

1.2.4 Operatori Genetici 11

1.2.5 Speciație 13

1.2.6 Reproducerea 14

2 rtNEAT **15**

2.1 Inlocuirea agentului cel mai putin adaptat 15

2.2 Generarea copilului 16

2.3 Parametrii de rulare a algoritmului 17

3 Mediul Virtual **18**

3.1 Titlul secțiunii 1 18

3.2 Titlul secțiunii 2 19

4 Detalii de implementare **20**

4.1 Titlul secțiunii 1 20

4.2 Titlul secțiunii 2 21

5 Setari experimentale **22**

5.1 Titlul secțiunii 1 22

5.2 Titlul secțiunii 2 23

6 Rezultate **24**

6.1 Titlul secțiunii 1 24

6.2 Titlul secțiunii 2 25

Concluzii **26**

Motivație

Pe parcursul dezvoltării discipline informaticii, natura a servit ca inspirație pentru oamenii de știința care se ocupau cu dezvoltarea de noi algoritmi. Astfel a aparut clasa de **algoritmi evolutivi**, din care se branșează mai departe alte familii de algoritmi: **algoritmii genetici**, **strategii evolutive**, **programarea genetica** și **algoritmii de neuro-evoluție**.

Aceasta familie de algoritmi a ajutat la dezvoltarea multor solutii unde algoritmii clasici deterministi sunt prea costisitori sau ineficienti. Un exemplu ar fi o antena X-band evoluata pentru misiunea NASA din 2006 numita Space Technology 5, al carei design a fost gasit prin intermediul unui algoritm evolutiv[Hor+06].

Pe parcursul timpului, studiul in natura a intercatiunilor dintre prada si pradator a permis extragerea de informatii valoroase despre dinamica ecosistemelor. Datorita avansului rapid al inteligentii artificiale si a algoritmilor evolutivi, avem oportunitatea de a cerceta aceste intercatiuni intr-un mediu virtual.

Aceasta teza de licenta propune utilizare algoritmilor **NEAT**(NeuroEvolution of Augmenting Topologies) si **rtNEAT**(real time NEAT), plus mediul de dezvoltare de jocuri **Unity**(2D) pentru crearea unei simulari dinamice a intercatiunilor dintre speciile de prada si cele pradator. Intelegerea acestor intercatiuni este esentiala pentru a descoperi factorii care influențează dinamica populațiilor, coexistența speciilor și stabilitatea ecosistemelor. Utilizand un mediu virtual, putem studia interactiunile prada-pradator in izolatie, putem controla variabilele de mediu, si putem repeta experimente de mai multe ori intr-un mod consistent(relativ la variabilitatea naturii). Algoritmul NEAT, datorita capacitatii sale de a evolua atat ponderile cat si topologiile rețelelor neuronale, reprezinta un motor puternic pentru modelarea comportamentelor și proceselor de luare a deciziilor ale prădătorilor și prăzii, cu scopul de a supravetui mai mult. Prin evoluția rețelelor neurale ale prăzii, putem explora comportamentele de căutare a hranei, tactici de evitare și strategii de supraviețuire, iar pradatorii ar trebui sa dezvolte

strategii de vanatoare, cu adaptari pentru schimbarile din mediu.
Motorul de joc Unity permite sa vizualizam in timp real comportamentele pe care le dezvolta orgnismele, sa monitorizam noile specii care apar din ambele categorii de organism, sa adaugam potential noi obstacole, noi senzori, sau noi abilitati prazii si pradatorilor, si sa controlam variabilele si viteza simularii.
În concluzie, această teză de licență își propune să îmbine domeniile inteligenței artificiale, al evolutiei biologice si al ecologiei, utilizând algoritmul NEAT și Unity pentru a simula interacțiunile dintre pradă și prădători. Prin studierea acestor dinamici ne propunem sa contribuim intelegerea sistemelor ecologice, cat și la educare populatiei pe larg asupra acestor interactiuni prin intermediul vizualizarilor. Ipoteza noastra e ca studiind evolutia populatiilor prazii si pradatorilo aceste se vor conforma ecuatiilor Lotka-Voltera.

Introducere

În ciuda faptului că dinamica populației a atras din punct de vedere istoric interesul multor oameni de știință, suntem încă departe de a înțelege cum și de ce populațiile fluctuează în ecosistemele naturale. Motivul principal este că populațiile sunt sisteme complexe, cu proprietăți emergente care sunt imposibil de determinat prin suma părților lor.[Oro13]
Intr-un mediu virtual, am putea izola si controla variabilele din mediu pentru a studia anumiti factori specifici care influenteaza aceasta dinamica. Specific, vom simula si studia interactiunile prada-pradator, impactul lor reflectându-se in dinamica populatiei in urmatoarele moduri:

- **Reglarea populatiei** - prădarea reprezinta un mecanism regulator atat pentru populatia prazii cat si a pradatorilor, ce previne prada din a ajunge la densitati prea mari, iar densitatea prădătorilor e controlata de cea a prazii.

- **Dinamica ciclica a populatiei** - interactiunile prada-pradator pot rezulta in ciclicitate a populatiilor, unde numarul prazii si a pradatorilor pot sa prezinte fluctuatii in timp in mod regulat. In studierea impactului pe care l-ar avea incalzirea globala asupra dinamicii sistemelor ecologice sa observat chiar ca durata acestor cicluri se micsoreaza trecand de la temperaturi calde la cele mai reci[DeL20].

- **Dinamici evolutive** - presiunea impusa de mecanismul de pradare poate duce la adaptari evolutive. In mediul natural prăzile pot dezvolta mecanisme defensive(coarne, camuflaj, viteza) iar pradatorii deasemenea pot suferi schimbari fizice dar si in strategiile de vanatoare.

În aceasta lucrare vom dezvolta un mediu virtual cu o populație de prada și una de prădători, cu scopul de a analiza transformarile suferite in populatii dupa criteriile de mai sus. Mediul va fi dezvoltat in motorul de jocuri Unity, si il vom descrie in capitolul 3.El va include 4 pereti pozitionati pentru a crea o arie inchisa. In cadrul acelei

arii vor fi generati in mod constant peleti de energie care vor fi consumati de prada, va fi generata populatia de prada si populatia de pradatori. Evolutia organismelor din fiecare populatie se va preta pe dezvoltarea comportamentelor, nu a trasaturilor fizice. Pentru a directiona aceasta evolutie, vom folosi un algoritm din clasa algoritmilor evolutivi.

De-a lungul dezvoltarii familiei de algoritmi evolutivi, apar anumite etape cheie in care se dezvolta ramuri noi. Enumeram cateva din ramuri in urmatorul mod:

- **Algoritmii Genetici**(GA) - arie de studiu în care pionier este John Holland prin cartea sa "Adaptation in Natural and Artificial Systems", publicată în 1975[Hol92]. In ea el introduce utilizarea unei populatii de indivizi, a operatorilor genetici precum mutatie si crossover, si a mecanismelor de selectie inspirate de selectia naturala.

- **Strategii Evolutive**(ES) - dezvoltarea acestei ramuri poate fi atribuita lui Rechenberg și Hans-Paul Schwefel care sau ocupat de studiul ei în anii '60 și '70. In 1973 Rechenberg publica cartea "Evolutionsstrategie"[Rec73], in care documenteaza cercetarea sa pe probleme de optimizare continua.

- **NeuroEvolutie** - aceasta clasa de algoritmi cauta prin spatiul de ponderi si structuri o retea neuronala cu performante bune pentru a anumita sarcina. Practic algoritmii de neuroevolutie permit gasirea unui comportament care faciliteaza rezolvarea problemelor de **reinforcement learning** complexe[MM95]. De obicei, in cadrul algoritmilor NE, se alege o tipologie(structura de noduri si conexiuni) pentru retele ce urmeaza sa treaca prin procesul de evolutie, iar schimbarile au loc doar pe ponderile conexiunilor. **NEAT** este o abordare inedita a neuroevolutiei pe parcursul careia se modifica atat tipologia retelei cat si ponderile conexiunilor. Astfel este scutit efortul uman de a crea designul unei retele. La inceptia acestei metode a stat Kenneth O. Stanley, cu articolul s-au din 2002 "Evolving Neural Networks through Augmenting Topologies"[SM02]

In cadrul acestei teze, comportamentele fiecarui individ din populatie, adica actiunile pe care le fac la fiecare pas de timp vor fi dictate de cate o retea neuronala. Ca algoritmi de neuroevolutie vom folosi **NEAT** si **rtNEAT**. Acesti algoritmi vor fi descrisi fiecare in capitolele 1 si 2.In cadrul unui experiment in care vom include doar speciile de prada, in care excludem analiza populatiei ca numar de indivizi, vom identifica care

dintre algoritmi determina o progresie mai rapida in materie de acumulare de energie in medie si cata energie acumuleaza cel mai bun membru al populatiei. Un experiment similar a fost descris in lucrarea lui T. Gelles si M. Sanchez[Gel16] in care incearca sa evolueze comportamentul furnicilor de a plasa feromoni ca un mod de a comunica, si demonstreaza ca **rtNEAT** are mai mult succes in a evolua acest comportament decat **NEAT**.

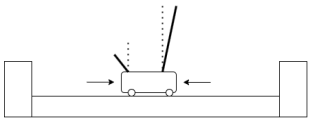
Pentru alte experimente in materie de interactiune prada-pradator putem face referinta la lucrarea "An evolutionary approach for interactive computer games"[YLH04]. In cadrul ei autorii proiecteaza un joc numit "Dead End", in care jucatorul are scopul de a ajunge la iesirea din partea opusa a ecranului de unde este el generat, iar o echipa de 8 "Dogs", ai caror miscari sunt dictate de cate o retea neuronala, au scopul de al prinde inainte ca acesta sa ajunga la iesire, deci trebuiau sa dezvolte comportamente de urmarire si de cooperare. Pentru evolutia cainilor au fost folositi 2 algoritmi de invatare proprii, unul offline si unul online. Ambii aduceau schimbări doar ponderilor conexiunilor din retea, nu si a topologiei retelelor. Ei au identificat ca agentii antrenati in modul online prezinta o adapabilitate mare la schimbarea strategiilor de joc a jucatorilor, deci demonstreaza eficacitatea metodei impotriva jucatorilor umani.

Datorita concluziilor acestor 2 lucrari, vom sustine ipoteza ca **rtNEAT**, care este un algoritm de invatare online, va determina o evolutie mai rapida a indivizilor, in termeni de energie acumulata. Deasemenea, doar**rtNEAT** ne permite sa facem o analiza a populatiilor pe timp indelungat, deoarece **NEAT** reseteaza populatile la fiecare generatie. Daca identificam ca **NEAT**, care este un algoritm offline, produce o invatare mai rapida, il vom folosi pentru a evolua comportamentele indivizilor, iar retelele antrenate astfel le vom integra in **rtNEAT** pentru a face analiza dinamicii populatiei. In capitolul 4 vom detalia implementarea mediului, a algoritmilor, a retelelor, si a senzorilor folositi. In capitolul 5 vom prezenta experimentele pe care vrem sa le conducem si setarile pentru algoritmi in cadrul experimentelor. In final, 6 prezentam rezultatele si anlizam care sunt factorii care le-au influentat.

Capitolul 1

NEAT

Algoritmul NEAT a fost descris pentru prima oara de Keneth O. Stanley si Risto Miikkulainen in articolul lor ”Evolving Neural Networks through Augmenting Topologies”[SM02]. In abordarile clasice ale **NeuroEvolutiei**(NE), se alege o topologie initiala a retelelor neuronale iar in timpul experimentelor algoritmii cauta doar in spatiul ponderilor conexiunilor. Ins topologia(structura) retelelor area deasemenea un impact asupra comportamentelor pe care le formeaza o retea. Un argument bun pentru a aplica evolutia atat asupra ponderilor cat si topologiei vine din partea lui Gruau[Gru93], care sustinea ca evolutia structurii unei retele economiseste timpul pe care l-ar fi folosit un om in a decide topologia pentru o anumita problema de NE. A demonstrat asta evoluând topologia si conexiunile unei retele care a reusit sa rezolve cel mai dificil benchmark de pole balancing de atunci(1996), double pole balancing.



Totusi, aceasi problema a fost rezolvat de 5 ori mai rapid de **Enforced Subpopulations**(ESP)[GM99], astfel, autorii NEAT si-au propus sa demonstreze un argument mai puternic pentru evolutia structurilor, anume ca modificand atat topologia cat si ponderile putem spori cu mult performanta algoritmilor NE. NEAT poate face asta datorita faptului ca minimizeaza structurile retelelor pe tot parcursul algoritmului. Au existat pe parcursul timpului mai multe metode de evolutie atat pentru topologiile cat si ponderile retelelor neuronale, ale caror ideii autorii le-au unit in [SM02] sub termenul de **”TWEANS”**(Topology and Weight Evolving Artificial Neural Networks). Pentru dezvoltarea NEAT Kenneth O. Stanley a adresat un numar de probleme nerezolvat la clasa de algoritmi TWEANS. Inainte de asta ar trebui totusi sa prezentam cum functioneaza retelele neuronale si modul lor de a invata.

1.1 Retele Neuronale Artificiale

In natura, o retea neuronala reprezinta o retea de neuroni interconectati, care sunt responsabili de functionarea sistemului nervos. Sunt specializati in transmiterea informatiei prin semnale electrice si au 4 componente principale, dendritele, corpul celular, axonul si butonii terminali.



Fiecare neuron primeste informatie prin dendrite si le trasmite prin axon printr-un semnal electric cu toata puterea sa, daca a primit destula informatie prin Dendrite. Neuronii sunt conectati intre ei prin sinapse, iar sinapsele isi pot adapta numarul de receptori pentru a controla puterea semnalului care vine de la un neruon. O retea neuronala artificiala este compusa dintr-o serie de noduri conectate intre ele ca un graf. Ca structura, o retea are un strat de noduri de iesire, unul de noduri de iesire, iar retelele deep au si un numar de straturi ascunse. Fiecare conexiune are o pondere asociata ei ce reprezinta puterea conexiunii. Aceste ponderi se pot adapta astfe incat reteau sa functioneze conform asteptarilor. Conform Teoriei Aproximarii Universale, o retea neuronala ar putea sa ajunga aproape de a a aproxima orice functie pentru care este conceputa. Spre deosebire de creier, in o retea neuronala pot exista mai multe tipuri de neuroni, determinati de o functie de activare. Daca nu folosim o functie de activare, valoarea unui neuron este reprezentata de o suma ponderata a intrarilor plus optional un bias al neuronului.



Daca este folosita o functie de activare, atunci semnalul nodului va fi outputul functiei de activare, iar input-ul este suma ponderata dintre conexiunie si intrarile nodului.

Retelele neuronale artificiale traditionale sunt feedforward, adica datele sunt procesate intr-o singura directie, de la input la output, iar invatarea se face prin algoritmul de backpropagation. In documentul care descrie NEAT, nu sunt expuse restrictii asu-

pra conexiunilor care se pot forma, deci algoritmul poate duce la generarea retelelor neuronale recurente.



Acestea pot procesa date secventiale, deoarece contin conexiuni ciclice, ce se pot forma intre oricare noduri, inclusiv nodul de la care conexiunea a pornit. La fiecare pas de timp, in RNN nodurile proceseaza atat intrarea curenta cat si iesirea nodului recurent anterior, ceea ce permite retelei sa utilizeze informatii din trecut. Pentru antrenare NEAT nu foloseste backtracking, ci operatorii genetici.

1.2 Problemele in TWEANNs si inovatiile in NEAT

1.2.1 Codificare

O problema pe care trebuie sa o rezolve orice TWEANN este modul in care specificam genomul unui individ. Aici sunt doua categorii mai mari, **codificare indirecta** si **directa**. Codificarea indirecte de obicei doar specifica reguli pentru crearea fenotipului, si sunt specifice algoritmilor care le folosesc Pentru codificarea directa optiuni sunt **codificarea binara**, care foloseste codificare clasica a grafurilor cu siruri de biti, precum "Structured Genetic Algorithm"(sGA)[DM92], care reprezinta prin siruri de biti matriciea de conexiuni a retelei, insa cele mai intalinte codificari sunt cele de tip graf, care reprezinta grafurile in mod mai explicit. NEAT foloseste o codificare directa, din cauza ca codificarile indirecte neavand un maping direct la fenotip, daca nu suntem foarte familiari cu procesele genetice, cautarea poate fi perturbata in moduri inpredicitibile si greu de detectat. Codificare pe care o alegem este foarte importanta, deoarece aceasta afecteaza costul operatiei de crossover, astfel ca exista TWEANNs "nonmating", care nici macar nu folosesc acest operator

Codificarea NEAT a fost proiectata cu scopul de a permite alinierea genom-urilor pen-

tru crossover fara a fi nevoie de o analiza costisitoare a topologiei. Aceasta codificare este reprezentata de o lista de node genes, si o lista de connection genes. Pentru fiecare node gene este specificat id-ul sau si tipul de nod, care clasifica nodurile in noduri de intrare, de iesire, si noduri ascunse. Primele sunt nodurile de intrare, dupa care cele de iesire iar cele hidden sa adauga la capatul listei in urma mutatiilor. Fiecare conection gene contine: un in-node si un out-node, care exprima nodurile si directia conexiunii, ponderea asociata cu conexiunea, o valoare boolean care indica daca conexiunea ar trebui sa fie exprimata in fenotip, si un numar de inovatie(prezentam de ce este necesar in sectiunea 1.2.3), care permite gasire geneleor care corespund din diferiti indivizi si e una din piesele centrale ale algoritmului.



Figura 1.1: Genotipul și fenotipul exprimat de acesta

1.2.2 Initializarea populatiei

La majoritatea algoritmilor din clasa TWEANN, populatia initiala este generata cu topologii random, pentru a asigura diversitate in structurile retelelor. Totusi, initializare in modul asta produce multe probleme pentru TWEANNS:

1. Nu avem nici o garantie ca informatia poate ajunge din fiecare intrare la fiecare iesire, ceea ce poate face ca unele intrari sa fie irelevante. Timp important de procesare va fi pierdut pentru a scapa de astfel de retele.

2. Ideal am dori ca solutiile obtinute sa fie minime, adica un numar minim de noduri si conexiuni, deoarece o retea mai complexa necesita mai mult timp pentru optimizarea ponderilor. Cu initilizare random, o mare parte din timp ar fi folosita pentru filtrarea structurilor extra care nu ar fi trebuit sa existe de la început. Evaluarea relelor mai complexe ia mai mult timp, dar prin aceasta initializare nu avem nici o garantie ca solutia va fi minima, deoarece orice retea atata timp cat are un fitness mare poate domina peste celelalte.

Solutia NEAT este sa inceapa in mod minim. Populatia initiala are fiecare nod de intrare conectat cu cele de iesire cu ponderi random, si nici un nod ascuns, astfel solutia va adauga structuri noi doar atunci cand aceste ajuta la imbunatatirea fitness-ului. Astfel se asigura minimalitatea nu doar la final dar pe parcursul tuturor generatiilor. Ar trebui sa precizam ca initial, adaugand unei retele structuri noi, care nu au fost optimizate, va face ca fitness-ul sa scada initial, deci indivizii cu inovatii topologice sunt la risc sa dispara, asta fiind un alt motiv pentru care majoritatea algoritmilor TWEANN folosesc initializare cu topologii random. Pentru a evita pierderea inovatiilor, NEAT foloseste **"Speciatiea"**, pe care o vom detalia in sectiunea 1.2.5.

1.2.3 Problema conventiilor concurente si numerele de inovatie

Problema conventiilor concurente apare atunci cand exista mai mult de un singur mod de a reprezenta o retea neuronala optimizata pentru o problema. Crossover in cazul a doua astfel de solutii poate duce la pierderea de informatie in cadrul noului copil format. Aceasta problema este inca mai grava in cadrul TWEANNs, deoarce solutii pentru o problema pot fi reprezentate prin topologii complet diferite, iar genomul fiecăreia poate avea lungimi diferite, agravand problema conventiilor concurente. Solutia in cadrul NEAT la aceasta problema este inspirata din solutia naturii in cadrul reproducerii sexuale, adica **omologia**, doua gene fiind omoloage daca ele sunt trasaturi ale aceleiasi alele. NEAT stabileste omologia dintre gene prin intermediul **marcatorilor istorici**, reprezentati de **numere de inovatie**, care permit stabilirea originii istorice a unei gene, iar astfel putem identifica si genele omoloage. Vom presznta cum apar si cum sunt folosite numerele de inovatie in sectiunile 1.2.4 si 1.2.5

1.2.4 Operatori Genetici

NEAT foloseste 2 operatori genetici pentru modificarea genomul-ui indivizilor, mutatia (fig 1.2) si crossover. Prin mutatie, ca si la ceilalti algoritmi de NE, se pot modifica ponderile, prin perturbarea lor sau prin asignarea unei noi valori random, insa pentru NEAT mutatie este si modalitate prin care introducem schimbari structurale. Sunt folosite 2 tipuri de mutatie structurala, "add connection", prin care se adauga o conexiune cu pondere random intre oricare 2 noduri care nu erau conectate deja, si "add node", care alege o conexiune in mod aleatoriu, si adauga un nou nod in locul ei. Mai exact, conexiunea aleasa este dezactivata, si se creaza o noua conexiune intre

nodul de intrare al conexiunii dezactivate si nodul nou creat, cu ponderea de 1, iar conexiunea dintre nodul nou si nodul de iesire primeste ponderea celei dezactivate. Astfel se minimizeaza efectul initial al modificarilor structurale, iar ponderile noilor conexiuni vor fi modificate in generatiile viitoare. De fiecare data cand producem o



Figura 1.2: Cele 2 tipuri de mutatie, ”add connection” si ”add node”

modificare structurala, fiecare gena de conexiune are adaugat si un nou numar de inovatie din punct de vedere global. Acest numar ne permite sa stabilim originea istorica a acestei gene. Daca in cursul unei generatii, pastram o lista a inovatiilor care au avut loc iar in genomul a 2 indivizi diferiti va aparea o aceasi gena de conexiune, poate doar cu ponderi diferite, aceste gene vor primi ambele acelasi numar de inovatie, pentru ca reprezinta aceasi structura dar care a aparut in mod indepedent in cadrul fiecareai. Crossover reprezinta incrucisarea genomului celor 2 parinti, pentru a crea un copil ce are structuri din partea ambilor Acum, datorita marcatorilor istorici, in cadrul crossover doua genomuri pot fi aliniate dupa genele care au numere de inovatie egale, acestea sunt gene ”matching”. Genele care nu sunt matching sunt fie ”disjoint” daca sunt in limita numerelor de inovatie a ambilor parinti, fie ”excess” daca unul din parinti are numere de inovatii mai mari decat cel mai mare numar al celuilalt parinte. In cadrul



Figura 1.3: Procesul de ”matching” pentru doua genomuri diferite

compunerii copilului, acesta mosteneste in mod aleator genele matching ale ambilor parinti, insa doar genele disjoint si excess ale parintelui cu cel mai mare ”fitness”. In

cazul in care ambii parinti au fitness egal, atunci si genele excess si disjoint sunt mostenite aleator. Pentru genele dezactivate, este o probabilitate prestabilita ca o gena sa ramana dezactivata daca ea e asa in cadrul oricaruia dintre parinti.
Prin intermediul acestor 2 operatori genetici, este introdusa diversitate in cadrul populatiei. Totusi, de obicei, datorita faptului ca strutucturile mai mici au mai putin conexiuni, aceste se pot optimiza mai rapid, iar adaugarea de noi structuri, pana acestea sunt optimizate, va scadea din fitness-ul retelei, deci inevitabil noile inovatii ar disparea rapid din o populatie normale, cu tote ca potential ele ar fi chiar necesare. Din acest motiv in NEAT este nevoie de **Speciatie**, pe care o prezentam in sectiunea 1.2.5.

1.2.5 Speciație

Speciatia este un mod de a proteja noile inovatii topologice aparute. Ideea este de a permite indivizilor sa concureze in propria lor nisa, nu cu intreaga populatie. Pentru a detalia, topologiile similare din cadrul populatiei vor fi incadrate in specii, organismele din aceleasi specii concureaza in principal intre ele, si astfel au timp sa isi optimizeze conexiunile. Cum anume sunt determinate speciile si organismele din cadrul lor? Tot cu ajutorul numerelor de inovatie. Numarul de gene ”desjoint” si ”excess” sunt un indicator bun al distantei din punct de vedere al compatibilitatii intre 2 genoame. Astfel, autorii NEAT au ajuns la o formula simpla care sa masoare compatibilitatea ca o distanta intre 2 structuri diferite in NEAT(notam δ) in termeni de numar de gene excess E si numar de gene desjoint D, plus media diferentei dintre genele matching $\overline{W}$:

$$\delta = \frac{c1 * E}{N} + \frac{c2 * D}{N} + c3 * \overline{W} \tag{1.1}$$

Coeficientii $c1$, $c2$ si $c3$ ajusteaza importanta acestor factori, iar N, care reprezinta numarul de connection genes a genomului cel mai lung, normalizeaza valorile conform dimensiunii genomului. Prin calculul valorii $delta$ putem desfasura procesul de speciatie cu ajutorul unei valori stabilite in prealabil, pragul de compatibilitate δt. Procesul de speciatie se desfasoara in urmatorul mod. Fiecare specie are un genom care o reprezinta. Fie un genom g din generatia curenta, acesta este plasat in prima specie cu a carui reprezentant este compatibil, adica $\delta < deltat$. Daca nu exista nici o specie compatibila, se formeaza una noua cu g ca reprezentat al acesteia.

1.2.6 Reproducerea

NEAT foloseste un mecanism numit **"explicit fitness sharing"** pentru a evita ca o specie sa devina prea mare si sa ajunga de dimensiunea intregii populatii. Practic, toate organismele din aceasi specie impartasec fitness-ul speciei lor. Fitness-ul ajustat al organismului i este calculat prin formula:

$$f\prime_i = \frac{f_i}{\sum_{j=1}^{n} sh(\delta(i,j))} \tag{1.2}$$

unde $f\prime_i$ e fitness-ul ajustat al individului i, n e numarul de organimse din populatie, iar functia sh are valoare 0 cand $\delta(i,j)$ este peste δ_t, dar 1 altfel. Astfel, partea de jos a fractiei reprezinta doar numarul de indivizi din aceasi specie cu organismul i. Fiecarei specii ii este acordat un numar diferit de membri potentiali depinzand de suma a $f\prime_i$ a membrilor speciei dupa formula:

$$n_k = \frac{\overline{F_k}}{\overline{F_{tot}}}|P| \tag{1.3}$$

unde k reprezinta o specie, n_k e nr de membri asignati speciei, $|P|$ este numarul de indivizi in populatie, $\overline{F_k}$ este media fitnessului speciei, adica $\overline{F_k} = \sum_i f\prime_i$, iar $\overline{F_{tot}} = \sum_k \overline{F_k}$ Intreaga populatie este apoi inlocuita de copii membrilor mai buni ai fiecarei specii, membrii mai slabi fiind eliminati in prealabil. Scopul final al speciatiei este protejare inovatiilor topologice, iar sistemul intreg cauta o solutie in cel mai rapid mod posibil, deoarece inovatii noi apar si sunt pastrate doar atunci cand e necesar.

Capitolul 2

rtNEAT

rtNEAT este o metoda bazata pe NEAT(vedeti capitolul 1), dezvolata de aceasi autori plus Bobby D. Bryant[SBM05]. Acesta este o adaptare a NEAT, gandit pentru jocuri, pentru evolutia retelelor neuronale in real-time, permitand agentilor controlati de ele sa se imbunatateasca in timpul desfasurarii jocului. Penru a demonstra acest concept de joc, a fost dezvoltat "NERO"(Neuro-Evolving Robotic Operatives)[Uni03], un joc bazat pe rtNEAT, in care un jucator antreneaza o echipa de roboti virtuali pentru a se lupta cu robotii altei echipe. Una dintre principalele observatii care au permist dezvoltarea rtNEAT este faptul ca intrun joc toata populatia joaca in acelasi timp, deci fitness-ul este inregistrat constant, astfel agentii tot sar putea adapta constant. Am considerat acest algoritm potrivit deoarece in mediul nostru virtual, ne dorim ca organismele sa evolueze si sa se adapteze in real-time, pe baza raspunsurilor pe care le primesc de la diversele interactiuni cu mediul, astfel am putea vedea o evolutie in termeni de comportamente cat si ca numar de indivizi, deoarece algoritmul NEAT reseteaza populatia la fiecare generatie.
In cadrul rtNEAT, la fiecare n intervale de timp, se executa o serie de operatie pentru inlocui un organism cu performante scazute cu copilul dintre 2 organisme mai performante, alese in mod probabilist astfel incat sa prezerve speciatia din NEAT.

2.1 Inlocuirea agentului cel mai putin adaptat

Prin aceasta operatie, se inlocuieste un agent putin performant cu unul potential mai performant, dar in asa fel incat se pastreaza dinamica de speciatie din NEAT. Pentru asta, alegem sa eliminam agentul cu cel mai mic "fitness ajustat", deoarece daca



Figura 2.1: Ciclul de inlocuiri in cadrul rtNEAT

alegerea sar face dupa cel mai rau fitness "neajustat", ar fi eliminate intii organismele din specii in care a aparut o inovatie topologica noua si care nu a avut timp sa se optimizez, astfel speciatia nu ar mai proteja inovatia. Fitness-ul ajustat este calculat la fel ca in cadrul NEAT, adica pentru individul i, $f\prime_i = \frac{f_i}{|S|}$, $|S|$ fiind numarul de indivizi din aceasi specie cu i.

Trebuie deasemenea sa ne asiguram ca fiecare individ a supravetuit destul inainte sa fie eliminat, deoarece altfel ar fi eliminati mereu cei mai noi indivizi, care nu au avut timp sa acumuleze fitness. Din acest motiv, rtNEAT elimina doar agentii care au supravetuit minimul de timp m. Acest parametru e setat experimental. Dupa eliminarea unui agent, este important sa estimam din nou fitnessul mediu $\tilde{F}$, deoarce acesta se schimba, si este folosit in urmatorul pas al algoritmului.

2.2 Generarea copilului

Din cauza ca nu generam din nou intreaga populatie la inceputul fiecarei populatii, nu poate fi utilizata formula 1.3, dar dinamica speciatie poate fi conservata daca alegem parintele in mod probabilist:

$$Pr(S_k) = \frac{\overline{F_k}}{\overline{F_{tot}}} \tag{2.1}$$

adica probabilitate de a alege o specie anume pentru parinti este proportionala cu raportul dintre fitness-ul mediu al speciei si suma fitness-urilor medii pentru toate speciile. Noul copil este format prin crossover dintre 2 indivizi din specia aleasa plus mutatie.

Daca folosim un prag de compatibilitate dinamic δ_t, atunci nu putem face la fel ca in "NEAT", adica sa il actualizam inainte de crearea urmatoarei generatii, deoarece aproape toata populatia va ramane in aceasi specie. In rtNEAT, este ales un numar de

inlocuiri de indivizi intre care se fac ajustari ale δ_t, de exemplu la fiecare 3 inlocuiri, iar pe baza noului δ_t fiecare individ din populatie va fi repartizata din nou la una speciile existente.

2.3 Parametrii de rulare a algoritmului

Toti pasii algoritmului rtNEAT, pe care iam discutat mai sus, trebuie executati la intervale regulate, adica la fiecare n ticuri de timp. Parametrul n trebuie ales astfel incat rata de inlocuiere sa le permita agentilor sa supravetuiasca destul cat sa ajunga la timpul minim m, pentru a putea fi evaluati, adica sa treacat din statutul de neelegibili pentru inlocuire in eligibili, dar si destul de des cat sa nu se incetineasca evolutia la un grad frustrant. Pentru a determina parametrii potriviti, autorii au stabilit o lege a eligibilitatii, care stabileste ce proportie din populatie ne putem astept sa fie nelegibila odata ce algoritmul a trecut de primele generatii cand toata populatia este nelegibila:

$$I = \frac{m}{|P|n} \tag{2.2}$$

unde I e fractia nelegibila din populatie, m e durata minima de viata pe care o poate avea un individ, n este numarul de ticuri intre procesele de inlocuire, iar $|P|$ numarul de indivizi in populatie. Practic, cu cat este mai mare populatia si numarul de ticuri intre inlocuiri, cu atat este mai greu este inlocuita populatia in intregime, deci mai putini agenti neelegibili, iar cu cat m este mai mare, cu atat mai multi vor fi sub pragul eligibilitatii. Astfel, putem construi o formula pentru n:

$$n = \frac{m}{|P|I} \tag{2.3}$$

Astfel, parametri pe care trebuie sa ii alegem noi raman doar m, $|P|$ si I.
Procesele descrise pana acum permit rtNEAT sa replice dinamica NEAT, dar in real-time.

Capitolul 3

Mediul Virtual

Amet venenatis urna cursus eget. Quam vulputate dignissim suspendisse in est ante. Proin nibh nisl condimentum id. Egestas maecenas pharetra convallis posuere morbi. Risus viverra adipiscing at in. Vulputate eu scelerisque felis imperdiet. Cras adipiscing enim eu turpis egestas pretium aenean pharetra. In aliquam sem fringilla ut morbi tincidunt augue. Montes nascetur ridiculus mus mauris. Viverra accumsan in nisl nisi scelerisque eu ultrices vitae. In nibh mauris cursus mattis molestie a iaculis. Interdum consectetur libero id faucibus nisl tincidunt eget. Gravida in fermentum et sollicitudin ac orci. Suscipit adipiscing bibendum est ultricies. Etiam non quam lacus suspendisse. Leo urna molestie at elementum eu facilisis sed odio morbi. Egestas congue quisque egestas diam in arcu cursus. Amet consectetur adipiscing elit ut aliquam purus.

3.1 Titlul secțiunii 1

Eros donec ac odio tempor. Facilisi morbi tempus iaculis urna id volutpat. Faucibus in ornare quam viverra orci sagittis eu. Amet tellus cras adipiscing enim eu turpis egestas. Integer feugiat scelerisque varius morbi. Platea dictumst vestibulum rhoncus est pellentesque elit ullamcorper dignissim. Bibendum arcu vitae elementum curabitur. Eu nisl nunc mi ipsum faucibus. Id aliquet lectus proin nibh nisl condimentum id venenatis a. Cras adipiscing enim eu turpis egestas pretium. Quisque non tellus orci ac auctor augue mauris augue. Malesuada pellentesque elit eget gravida cum. Ut lectus arcu bibendum at. Massa id neque aliquam vestibulum morbi blandit. Posuere ac ut consequat semper viverra nam. Viverra adipiscing at in tellus integer feugiat

scelerisque varius morbi. Morbi enim nunc faucibus a pellentesque sit amet porttitor eget. Eu feugiat pretium nibh ipsum consequat nisl vel. Nisl purus in mollis nunc sed.

3.2 Titlul secțiunii 2

Elementum sagittis vitae et leo duis ut diam quam nulla. Purus sit amet volutpat consequat mauris nunc. Tincidunt augue interdum velit euismod in pellentesque massa. Nunc sed augue lacus viverra vitae congue. Porttitor leo a diam sollicitudin. Faucibus pulvinar elementum integer enim. Adipiscing bibendum est ultricies integer quis auctor elit. Blandit aliquam etiam erat velit scelerisque in. A iaculis at erat pellentesque adipiscing commodo elit at. Erat nam at lectus urna duis. Consequat ac felis donec et. Fermentum posuere urna nec tincidunt praesent semper feugiat nibh sed. Proin gravida hendrerit lectus a. Pretium viverra suspendisse potenti nullam ac tortor vitae purus. Arcu cursus euismod quis viverra nibh cras pulvinar mattis. Gravida arcu ac tortor dignissim convallis aenean. Quam nulla porttitor massa id neque aliquam vestibulum morbi. Sed viverra ipsum nunc aliquet. Quis enim lobortis scelerisque fermentum dui faucibus in.

Capitolul 4

Detalii de implementare

Amet venenatis urna cursus eget. Quam vulputate dignissim suspendisse in est ante. Proin nibh nisl condimentum id. Egestas maecenas pharetra convallis posuere morbi. Risus viverra adipiscing at in. Vulputate eu scelerisque felis imperdiet. Cras adipiscing enim eu turpis egestas pretium aenean pharetra. In aliquam sem fringilla ut morbi tincidunt augue. Montes nascetur ridiculus mus mauris. Viverra accumsan in nisl nisi scelerisque eu ultrices vitae. In nibh mauris cursus mattis molestie a iaculis. Interdum consectetur libero id faucibus nisl tincidunt eget. Gravida in fermentum et sollicitudin ac orci. Suscipit adipiscing bibendum est ultricies. Etiam non quam lacus suspendisse. Leo urna molestie at elementum eu facilisis sed odio morbi. Egestas congue quisque egestas diam in arcu cursus. Amet consectetur adipiscing elit ut aliquam purus.

4.1 Titlul secțiunii 1

Eros donec ac odio tempor. Facilisi morbi tempus iaculis urna id volutpat. Faucibus in ornare quam viverra orci sagittis eu. Amet tellus cras adipiscing enim eu turpis egestas. Integer feugiat scelerisque varius morbi. Platea dictumst vestibulum rhoncus est pellentesque elit ullamcorper dignissim. Bibendum arcu vitae elementum curabitur. Eu nisl nunc mi ipsum faucibus. Id aliquet lectus proin nibh nisl condimentum id venenatis a. Cras adipiscing enim eu turpis egestas pretium. Quisque non tellus orci ac auctor augue mauris augue. Malesuada pellentesque elit eget gravida cum. Ut lectus arcu bibendum at. Massa id neque aliquam vestibulum morbi blandit. Posuere ac ut consequat semper viverra nam. Viverra adipiscing at in tellus integer feugiat

scelerisque varius morbi. Morbi enim nunc faucibus a pellentesque sit amet porttitor eget. Eu feugiat pretium nibh ipsum consequat nisl vel. Nisl purus in mollis nunc sed.

4.2 Titlul secțiunii 2

Elementum sagittis vitae et leo duis ut diam quam nulla. Purus sit amet volutpat consequat mauris nunc. Tincidunt augue interdum velit euismod in pellentesque massa. Nunc sed augue lacus viverra vitae congue. Porttitor leo a diam sollicitudin. Faucibus pulvinar elementum integer enim. Adipiscing bibendum est ultricies integer quis auctor elit. Blandit aliquam etiam erat velit scelerisque in. A iaculis at erat pellentesque adipiscing commodo elit at. Erat nam at lectus urna duis. Consequat ac felis donec et. Fermentum posuere urna nec tincidunt praesent semper feugiat nibh sed. Proin gravida hendrerit lectus a. Pretium viverra suspendisse potenti nullam ac tortor vitae purus. Arcu cursus euismod quis viverra nibh cras pulvinar mattis. Gravida arcu ac tortor dignissim convallis aenean. Quam nulla porttitor massa id neque aliquam vestibulum morbi. Sed viverra ipsum nunc aliquet. Quis enim lobortis scelerisque fermentum dui faucibus in.

Capitolul 5

Setari experimentale

Amet venenatis urna cursus eget. Quam vulputate dignissim suspendisse in est ante. Proin nibh nisl condimentum id. Egestas maecenas pharetra convallis posuere morbi. Risus viverra adipiscing at in. Vulputate eu scelerisque felis imperdiet. Cras adipiscing enim eu turpis egestas pretium aenean pharetra. In aliquam sem fringilla ut morbi tincidunt augue. Montes nascetur ridiculus mus mauris. Viverra accumsan in nisl nisi scelerisque eu ultrices vitae. In nibh mauris cursus mattis molestie a iaculis. Interdum consectetur libero id faucibus nisl tincidunt eget. Gravida in fermentum et sollicitudin ac orci. Suscipit adipiscing bibendum est ultricies. Etiam non quam lacus suspendisse. Leo urna molestie at elementum eu facilisis sed odio morbi. Egestas congue quisque egestas diam in arcu cursus. Amet consectetur adipiscing elit ut aliquam purus.

5.1 Titlul secțiunii 1

Eros donec ac odio tempor. Facilisi morbi tempus iaculis urna id volutpat. Faucibus in ornare quam viverra orci sagittis eu. Amet tellus cras adipiscing enim eu turpis egestas. Integer feugiat scelerisque varius morbi. Platea dictumst vestibulum rhoncus est pellentesque elit ullamcorper dignissim. Bibendum arcu vitae elementum curabitur. Eu nisl nunc mi ipsum faucibus. Id aliquet lectus proin nibh nisl condimentum id venenatis a. Cras adipiscing enim eu turpis egestas pretium. Quisque non tellus orci ac auctor augue mauris augue. Malesuada pellentesque elit eget gravida cum. Ut lectus arcu bibendum at. Massa id neque aliquam vestibulum morbi blandit. Posuere ac ut consequat semper viverra nam. Viverra adipiscing at in tellus integer feugiat

scelerisque varius morbi. Morbi enim nunc faucibus a pellentesque sit amet porttitor eget. Eu feugiat pretium nibh ipsum consequat nisl vel. Nisl purus in mollis nunc sed.

5.2 Titlul secțiunii 2

Elementum sagittis vitae et leo duis ut diam quam nulla. Purus sit amet volutpat consequat mauris nunc. Tincidunt augue interdum velit euismod in pellentesque massa. Nunc sed augue lacus viverra vitae congue. Porttitor leo a diam sollicitudin. Faucibus pulvinar elementum integer enim. Adipiscing bibendum est ultricies integer quis auctor elit. Blandit aliquam etiam erat velit scelerisque in. A iaculis at erat pellentesque adipiscing commodo elit at. Erat nam at lectus urna duis. Consequat ac felis donec et. Fermentum posuere urna nec tincidunt praesent semper feugiat nibh sed. Proin gravida hendrerit lectus a. Pretium viverra suspendisse potenti nullam ac tortor vitae purus. Arcu cursus euismod quis viverra nibh cras pulvinar mattis. Gravida arcu ac tortor dignissim convallis aenean. Quam nulla porttitor massa id neque aliquam vestibulum morbi. Sed viverra ipsum nunc aliquet. Quis enim lobortis scelerisque fermentum dui faucibus in.

Capitolul 6

Rezultate

Amet venenatis urna cursus eget. Quam vulputate dignissim suspendisse in est ante. Proin nibh nisl condimentum id. Egestas maecenas pharetra convallis posuere morbi. Risus viverra adipiscing at in. Vulputate eu scelerisque felis imperdiet. Cras adipiscing enim eu turpis egestas pretium aenean pharetra. In aliquam sem fringilla ut morbi tincidunt augue. Montes nascetur ridiculus mus mauris. Viverra accumsan in nisl nisi scelerisque eu ultrices vitae. In nibh mauris cursus mattis molestie a iaculis. Interdum consectetur libero id faucibus nisl tincidunt eget. Gravida in fermentum et sollicitudin ac orci. Suscipit adipiscing bibendum est ultricies. Etiam non quam lacus suspendisse. Leo urna molestie at elementum eu facilisis sed odio morbi. Egestas congue quisque egestas diam in arcu cursus. Amet consectetur adipiscing elit ut aliquam purus.

6.1 Titlul secțiunii 1

Eros donec ac odio tempor. Facilisi morbi tempus iaculis urna id volutpat. Faucibus in ornare quam viverra orci sagittis eu. Amet tellus cras adipiscing enim eu turpis egestas. Integer feugiat scelerisque varius morbi. Platea dictumst vestibulum rhoncus est pellentesque elit ullamcorper dignissim. Bibendum arcu vitae elementum curabitur. Eu nisl nunc mi ipsum faucibus. Id aliquet lectus proin nibh nisl condimentum id venenatis a. Cras adipiscing enim eu turpis egestas pretium. Quisque non tellus orci ac auctor augue mauris augue. Malesuada pellentesque elit eget gravida cum. Ut lectus arcu bibendum at. Massa id neque aliquam vestibulum morbi blandit. Posuere ac ut consequat semper viverra nam. Viverra adipiscing at in tellus integer feugiat

scelerisque varius morbi. Morbi enim nunc faucibus a pellentesque sit amet porttitor eget. Eu feugiat pretium nibh ipsum consequat nisl vel. Nisl purus in mollis nunc sed.

6.2 Titlul secțiunii 2

Elementum sagittis vitae et leo duis ut diam quam nulla. Purus sit amet volutpat consequat mauris nunc. Tincidunt augue interdum velit euismod in pellentesque massa. Nunc sed augue lacus viverra vitae congue. Porttitor leo a diam sollicitudin. Faucibus pulvinar elementum integer enim. Adipiscing bibendum est ultricies integer quis auctor elit. Blandit aliquam etiam erat velit scelerisque in. A iaculis at erat pellentesque adipiscing commodo elit at. Erat nam at lectus urna duis. Consequat ac felis donec et. Fermentum posuere urna nec tincidunt praesent semper feugiat nibh sed. Proin gravida hendrerit lectus a. Pretium viverra suspendisse potenti nullam ac tortor vitae purus. Arcu cursus euismod quis viverra nibh cras pulvinar mattis. Gravida arcu ac tortor dignissim convallis aenean. Quam nulla porttitor massa id neque aliquam vestibulum morbi. Sed viverra ipsum nunc aliquet. Quis enim lobortis scelerisque fermentum dui faucibus in.

Concluzii

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Nunc mattis enim ut tellus elementum sagittis vitae et. Placerat in egestas erat imperdiet sed euismod. Urna id volutpat lacus laoreet non curabitur gravida. Blandit turpis cursus in hac habitasse platea. Eget nunc lobortis mattis aliquam faucibus. Est pellentesque elit ullamcorper dignissim cras tincidunt lobortis feugiat. Viverra maecenas accumsan lacus vel facilisis volutpat est. Non odio euismod lacinia at quis risus sed vulputate odio. Consequat ac felis donec et odio pellentesque diam volutpat commodo. Etiam sit amet nisl purus in. Tortor condimentum lacinia quis vel eros donec. Phasellus egestas tellus rutrum tellus pellentesque eu tincidunt. Aliquam id diam maecenas ultricies mi eget mauris pharetra. Enim eu turpis egestas pretium.

Bibliografie

[Rec73] Ingo Rechenberg, *Evolutionsstrategie; Optimierung technischer Systeme nach Prinzipien der biologischen Evolution. Mit einem Nachwort von Manfred Eigen*, Frommann-Holzboog, 1973.

[DM92] D. Dasgupta și D. McGregor, „Designing application-specific neural networks using the structured genetic algorithm", în *Proceedings of the International Conference on Combinations of Genetic Algorithms and Neural Networks*, ed. de D. Whitley și J. D. Schaffer, IEE Press, 1992, pp. 87–96.

[Hol92] John H. Holland, *Adaptation in Natural and Artificial Systems: An Introductory Analysis with Applications to Biology, Control and Artificial Intelligence*, Cambridge, MA, USA: MIT Press, 1992, ISBN: 0262082136.

[Gru93] Frederic Gruau, „Genetic Synthesis of Modular Neural Networks", în *Proceedings of the 5th International Conference on Genetic Algorithms, ICGA-93*, ed. de Stephanie Forrest, University of Illinois at Urbana-Champaign: Morgan Kaufmann, Iul. 1993, pp. 318–325, ISBN: 1-55860-299-2, URL: http://dl.acm.org/citation.cfm?id=645513.657409.

[MM95] David Moriarty și Risto Miikkulainen, „Efficient Reinforcement Learning Through Symbiotic Evolution", în *Machine Learning* 22 (Ian. 1995), DOI: 10.1023/A:1018004120707.

[GM99] Faustino Gomez și Risto Miikkulainen, „Solving Non-Markovian Control Tasks with Neuro-Evolution.", în Ian. 1999, pp. 1356–1361.

[SM02] Kenneth O. Stanley și Risto Miikkulainen, „Evolving Neural Networks through Augmenting Topologies", în *Evolutionary Computation* 10.2 (2002), pp. 99–127, DOI: 10.1162/106365602320169811.

[Uni03] Department of Computer Sciences University of Texas at Austin, *Neuro Evolving Robotic Operatives*, June 16, 2023, 2003, URL: https://nn.cs.utexas.edu/nero/.

[YLH04] G.N. Yannakakis, J. Levine și J. Hallam, „An evolutionary approach for interactive computer games", în *Proceedings of the 2004 Congress on Evolutionary Computation (IEEE Cat. No.04TH8753)*, vol. 1, 2004, 986–993 Vol.1, DOI: 10.1109/CEC.2004.1330969.

[SBM05] K.O. Stanley, B.D. Bryant și R. Miikkulainen, „Real-time neuroevolution in the NERO video game", în *IEEE Transactions on Evolutionary Computation* 9.6 (2005), pp. 653–668, DOI: 10.1109/TEVC.2005.856210.

[Hor+06] Greg Hornby et al., „Automated Antenna Design with Evolutionary Algorithms", în *Collection of Technical Papers - Space 2006 Conference* 1 (Sept. 2006), DOI: 10.2514/6.2006-7242.

[Oro13] Daniel Oro, „Grand challenges in population dynamics", în *Frontiers in Ecology and Evolution* 1 (2013), ISSN: 2296-701X, DOI: 10.3389/fevo.2013.00002, URL: https://www.frontiersin.org/articles/10.3389/fevo.2013.00002.

[Gel16] Sanchez M. Gelles T., „Comparing Adaptivity of Ants using NEAT and rt-NEAT", în (2016).

[DeL20] Lyon S. DeLong JP, „Temperature alters the shape of predator-prey cycles through effects on underlying mechanisms.", în *PeerJ* (2020), DOI: 10.7717/peerj.9377.